

AI私有化部署算力评估研报

政企行业售前工程师 · 算力规划完全指南

2026年8月

政企行业

算力选型

数据至2026Q2

AI私有化部署算力评估研报

完成日期：2026年8月15日

适用读者：政企行业售前工程师、IT架构师、算力规划负责人

适用行业：煤炭/政务/高校等需私有化部署的行业

数据周期：2025-2026年最新公开数据

执行摘要

当前国内大模型本地化部署已进入规模化落地阶段，**政企客户面临的核心挑战不再是“能不能跑”，而是“怎么选、怎么配、怎么管”**。根据IDC 2026年4月发布的报告，2025年中国市场AI加速卡总交付量达400万片，其中国产厂商交付165万片，市场份额跃升至41%[\(IDC · 2025年度中国云端AI加速器市场报告\)](#)。

模型选型层面：国内主流开源大模型已形成清晰梯队——**通义千问Qwen**系列以Apache 2.0协议和全面的中文优化成为政企本地化首选，**DeepSeek V3/V4**凭借MoE架构在同等算力下提供接近翻倍的模型能力，**智谱GLM-5.3**则以完善的离线私有化交付体系深耕政务/金融场景。三者均可在消费级显卡(≥8GB显存)上通过INT4量化运行，但生产级部署建议至少16GB显存[\(掘金 · 2025\)](#)。

算力评估的核心公式：总显存 ≈ 模型参数显存 + 并发数 × 单请求KV Cache + 系统开销。其中**KV Cache是并发场景下的主导变量**，计算公式为：KV Cache = 2 × 层数 × KV头数 × 头维度 × 序列长度 × 精度字节数。以Qwen3-4B为例，单token的KV Cache约为0.14 MiB，2000token上下文的单请求约占用280 MiB[\(CSDN · GPU服务器模型资源使用分析, 2026\)](#)。

推理框架层面：**vLLM**凭借PagedAttention技术实现了2-3倍于传统方案的吞吐量，是生产环境的通用首选；**TensorRT-LLM**在NVIDIA平台上可再提升12-15%的吞吐，但编译慢、灵活性差；**SGLang**的RadixAttention在RAG/多轮对话场景下比vLLM快20-29%；**LMDeploy**则是国产算力生态的最佳适配选择[\(CSDN · AI Infra全解, 2026\)](#)。

算力选型的反直觉发现：国产顶级芯片(昇腾910C)在推理场景下已达到H100的60-80%性能，且采购成本约为H100的50-60%，但**真正的差距不在单卡性能，而在软件生态和工程化成本**——国产卡部署需预留1-3个月的CUDA迁移适配期，不要按“一比一替换”的预期立项[\(36氪 · 国产GPU迎战英伟达H200, 2025\)](#) [\(九章云极 · 算力选型指南, 2026\)](#)。

政企最佳实践：鄂尔多斯政务外网侧已成功部署DeepSeek-R1大模型并与“根数据库”平台联通，彬长矿业孟村矿实现了基于本地化大模型的灾害治理知识库(推理速度20-30 token/s)，均验证了“本地大模型+RAG增强检索”架构在政企场景的可行性[\(鄂尔多斯市人民政府 · 2026\)](#) [\(中国网 · 彬长矿区AI知识库, 2025\)](#)。

一、国内本地化大模型盘点

1.1 主流开源大模型对比

截至2026年中，国内可用于本地化部署的大模型已形成较为成熟的生态。对于政企客户而言，**许可协议、硬件门槛、中文能力、信创适配**是四大核心选型维度。

模型系列	厂商	开源协议	典型版本	参数规模	最低显存 (INT4)	推荐显存 (FP16)	中文能力	核心优势
通义千问 Qwen	阿里	Apache 2.0	Qwen3-8B / 14B / 30B-MoE / 72B	8B~72B	4GB(8B) / 7GB(14B)	16GB(8B) / 28GB(14B)	☆☆☆☆	协议最宽松，中文优化好，生态最全
DeepSeek V3/V4	深度求索	商用需授权	V3-671B MoE / R1 / 7B / 14B / 70B	7B~671B	4GB(7B) / 35GB(70B)	14GB(7B) / 140GB(70B)	☆☆☆☆	MoE架构效率高，推理能力强
智谱 GLM	智谱AI	商用需授权	GLM-5.3 / GLM-4-9B / 90B	9B~90B	5GB(9B)	18GB(9B)	☆☆☆☆	政企私有化交付完善，长上下文强
MiniMax	稀宇科技	部分开源	M3文本大模型 / H3 视频模型	—	—	—	☆☆☆☆	多模态能力强，视频生成领先
零一万物 Yi	零一万物	Apache 2.0	Yi-1.5-6B / 34B	6B~34B	3GB(6B) / 17GB(34B)	12GB(6B) / 68GB(34B)	☆☆☆☆	长上下文(200K)，推理能力强

售前风险提示：Apache 2.0协议的模型(Qwen、Yi)可自由商用和修改，无法律风险；DeepSeek、GLM等模型需确认商用授权范围，特别是用于对外提供服务的场景。

通义千问Qwen系列是目前政企本地化部署最广泛的选择。其Qwen2.5-7B-Instruct在FP16精度下约需14GB显存，INT8量化后约8GB，INT4量化后仅需5GB，RTX 3060(12GB)即可运行基本版本(CSDN · Qwen2.5-7B部署指南, 2026)。Qwen3系列进一步推出了MoE架构的30B版本(总参数30B，激活参数约3B)，在同等计算开销下性能接近70B稠密模型(CSDN文库 · MoE对比, 2025)。

DeepSeek V3是MoE架构的标杆产品，总参数671B，每次推理仅激活约37B参数，用1/194的算力达到70B稠密模型相当的性能(CSDN · DeepSeek MoE, 2025)。但其本地化部署门槛较高——FP8精度下权重约671GB，加KV Cache后总显存需求超700GB，需要16×H100级别的集群。对于政企客户，更实际的选择是DeepSeek-7B/14B稠密版本，单卡4090即可部署(CSDN · DeepSeek资源需求, 2026)。

智谱GLM-5.3于2026年8月发布，重点强化了政企离线落地场景。模型原生支持200K超长上下文，支持FP4/FP8多档位量化压缩，可灵活适配不同规格的国产算力服务器。智谱采用“公有云API调用 + 本地离线部署”双线交付模式，大型政企单位优先落地私有化离线版本(今日头条 · 智谱GLM-5.3, 2026)。

1.2 闭源私有化部署方案

除了开源权重模型，国内主流大模型厂商均提供私有化部署的镜像/一体机方案，适合没有算法团队的政企客户：

厂商	私有化方案	交付形式	适用客户	典型硬件要求	许可模式
智谱AI	GLM私有化部署	软件授权+一体机	政务/金融/高端制造	2×A100/昇腾910B起	按年授权
MiniMax	海螺AI企业版	私有化镜像	政企多模态场景	4×A100起	按并发/年
百度智能云	文心一言私有化	一体机方案	大型国企/政务	8×H100级	项目制
商汤	日日新私有化	SenseCore平台	城市级/行业级	集群级	项目制

售前坑点：闭源私有化方案的优势是开箱即用、有厂商兜底，但存在三个常见坑——(1) **升级绑定：**模型版本升级需额外付费或重新签约；(2) **黑盒调试：**无法看到模型内部权重，出问题只能等厂商排查；(3) **并发限制：**很多方案按并发数收费，实际使用中容易超限。

二、稠密模型 vs MoE模型：通俗原理与选型

2.1 大白话理解两种架构

稠密模型(Dense Model)：就像一个“全能型诸葛亮”——不管你问什么问题，他全身上下所有脑细胞都要参与思考。优点是回答质量稳定、输出一致性高；缺点是越聪明(参数越多)越费脑子(算力)，而且规模大到一定程度后，增加脑子带来的提升越来越小(边际效益递减)。

用更精确的话说，稠密模型中**每个输入token都会激活所有参数**，计算量与参数量成正比。例如Qwen2.5-7B，每次生成一个token，70亿参数全部参与计算(CSDN · MoE原理, 2025)。

MoE模型(Mixture of Experts, 混合专家模型)：就像“三个臭皮匠顶个诸葛亮”——系统里有很多个专家(臭皮匠)，每个专家专门擅长某一类问题。你问一个数学题，系统只把数学专家叫出来干活；你问一个写作题，系统叫写作专家出来。这样整体模型可以很大(有很多专家)，但每次推理只用其中一小部分专家，计算量反而小。

MoE的核心组件有三个：

- **专家网络(Experts)：**通常是多个独立的前馈神经网络(FFN)，每个专家专精某类输入
- **门控网络(Gating Network)：**相当于“调度员”，决定每个token该去找哪个专家
- **路由策略(Routing)：**通过负载均衡机制，避免某些专家太忙、某些专家太闲

2.2 核心差异对比

对比维度	稠密模型 (Dense)	MoE模型 (Sparse)	对政企选型的影响
参数激活方式	所有参数全激活(100%)	仅激活Top-k个专家(通常10-20%)	MoE用更少算力实现更大模型能力
计算量与参数关系	线性正相关(参数翻倍，计算量翻倍)	弱相关(参数翻倍，计算量仅增10-30%)	MoE扩展模型容量更“便宜”
显存需求	与参数量正比(参数全要存)	总参数大但激活参数小	MoE更吃显存(所有专家要常驻)，但计算更省
训练/部署复杂度	低，生态成熟	高，需处理专家负载均衡	MoE部署门槛高，需要专业团队
输出一致性	高，全参数参与	略低，不同token走不同专家	对输出一致性要求高的场景(如公文)需评估
量化友好性	标准化流程	更适合量化(QMoE等技术)	MoE+量化可大幅降低部署门槛
典型代表	Qwen2.5-7B、Llama-3-8B	DeepSeek V3、Qwen3-30B-MoE、Mixtral 8x7B	政企小流量场景优先选稠密模型

底层逻辑：MoE模型的本质是用**显存换计算效率**。总参数量可以很大(提升模型上限)，但每次推理只激活一小部分(降低计算成本)。这意味着MoE模型对显存容量要求高(所有专家参数都要装进去)，但对计算能力的要求相对低(每次只算少数专家)。

2.3 国内本地化实际使用情况

政企业场景主流选择：在2025-2026年的政企私有化部署中，**稠密模型(7B-14B级别)仍然是绝对主力**。原因很简单：部署简单、生态成熟、成本可控，且大部分政务/企业场景(文档摘要、问答、知识库)并不需要百亿级以上的模型能力。

MoE模型的应用场景：MoE主要用于对模型能力有更高要求、且有一定技术团队的场景：

- **DeepSeek V3/V4**: 主要在互联网大厂和智算中心部署，政企客户通常通过API调用而非本地化
- **Qwen3-30B-MoE**: 总参数30B，激活参数约3B，适合在中等算力(2-4卡A100)上追求接近70B稠密模型的性能
- **行业MoE**: 部分厂商基于通用MoE架构，用行业数据微调后提供行业专用版本

典型案例: 民航新疆空管局的实践验证了选型逻辑——他们先后部署了DeepSeek-7B、DeepSeek-14B和Qwen3-30B三个模型，最终选择Qwen3-30B作为主力，原因是7B/14B参数规模较小，专业领域知识相对匮乏，而30B级别(MoE)模型具备更丰富的民航气象专业知识储备，无需本地知识库即可准确完成气象报文解码、民航法规检索等工作。硬件采用两块英伟达P5000显卡+128GB内存，可支持10人并发使用(Hans Publishers · 民航空管气象应用, 2025)。

售前建议: 给客户做方案时，不要一上来就推荐MoE大模型。建议按“从小到大”的思路：先用7B稠密模型做POC验证业务价值，确认需要更强能力时再升级到14B/32B。MoE只在客户明确有复杂推理需求、且有运维能力时再推荐。

三、量化技术详解：从FP32到INT4

3.1 大白话理解量化

量化是什么？ 想象一下，你要把一张高清电影存到手机里。原版是4K超清(FP32)，文件超大装不下。你可以转成1080P(FP16)——画质损失不大，体积小一半。再狠一点可以转成720P(INT8)——普通人看不出区别，体积又小一半。再压缩到480P(INT4)——凑近看能看到马赛克，但大概内容还是清楚的，体积只有原来的1/8。

量化的本质就是：**用更少的比特数来表示模型的参数权重，以可接受的精度损失换取显存占用的大幅降低和推理速度的提升。**

3.2 各精度格式详解

精度格式	每参数字节数	表示范围	显存占用比	精度损失	适用场景
FP32 (单精度浮点)	4字节	$\pm 3.4 \times 10^{38}$	100% (基准)	无	训练过程、高精度计算
FP16 (半精度浮点)	2字节	± 65504	50%	极小(<1%)	推理标准精度，训练混合精度
BF16 (脑浮点)	2字节	$\pm 3.4 \times 10^{38}$	50%	极小	训练更稳定，A100/H100优化
FP8 (8位浮点)	1字节	$\pm 448 / \pm 57344$	25%	较小(2-5%)	H100+新卡专用，推理加速
INT8 (8位整数)	1字节	-128~127	25-30%	中等(3-7%)	推理部署主流，吞吐优先
INT4 (4位整数)	0.5字节	-8~7	12-15%	较大(5-10%)	大模型压缩、低显存部署

关键区分: FP16和BF16都是2字节，但两者的“侧重点”不同。FP16精度高(尾数10位)但范围小；BF16精度稍低(尾数7位)但范围大(和FP32一样)。训练时BF16更稳定，不容易梯度爆炸；推理时两者差别不大。

3.3 显存占用计算公式

模型参数显存: 这是最基础的计算，也是硬门槛。

$$\text{模型参数显存 (GB)} = \text{参数量 (个)} \times \text{每个参数字节数} \div 1024^3$$

举例: Qwen3-7B模型(70亿参数)


- FP32: $7e9 \times 4 = 28e9$ 字节 $\approx$ **26 GB**

- FP16: $7e9 \times 2 = 14e9$ 字节 $\approx$ **13 GB**

- INT8: $7e9 \times 1 = 7e9$ 字节 $\approx$ **6.5 GB**

- INT4: $7e9 \times 0.5 = 3.5e9$ 字节 $\approx$ **3.3 GB**

不同量化精度下模型参数显存占用对比



注意：实际显存占用会比理论值大一些(约多10-20%)，因为需要存储CUDA上下文、运行时缓冲区等开销。例如FP16的7B模型，理论上14GB，但实际加载后约15-16GB(CSDN · 显存占用笔记, 2026)。

3.4 量化技术路线对比

INT4量化不是只有一种做法，不同的量化算法在精度保持、推理速度、硬件兼容三个维度上各有取舍：

量化方法	核心原理	精度保持(4bit)	推理速度	硬件要求	适用场景
GPTQ	逐层Hessian矩阵优化，最小化量化误差	良好(MMLU降~4.7%)	最快(2.5x FP16)	NVIDIA GPU	生产部署、追求速度
AWQ	激活感知权重保护，保留重要通道	最佳(MMLU降~3.1%)	快(2.2x FP16)	NVIDIA GPU	高精度要求、政企核心业务
GGUF	分块量化，专为CPU推理优化	一般(MMLU降~6.9%)	CPU上快	CPU/Apple Silicon/全平台	边缘部署、跨平台、无GPU
SmoothQuant	迁移量化难度到权重，实现W8A8	良好(INT8全量化)	快(有硬件加速)	支持INT8的GPU	全INT8推理、高吞吐场景
BitsAndBytes	加载时实时量化(NF4)	良好	中等	NVIDIA GPU	快速实验、微调(QLoRA)

数据来源：基于Llama-3-8B在MMLU基准测试的综合对比(CSDN问答 · AWQ/GPTQ/GGUF精度对比, 2025)

3.5 政企项目选型建议

- 优先用官方量化版本：不要自己量化！自己量化需要校准数据，数据选不好精度崩得一塌糊涂。优先用HuggingFace上官方发布的GPTQ/AWQ版本，如 [Qwen/Qwen2.5-7B-Chat-GPTQ](#)。
- 按业务敏感度选量化等级：
 - 公文/报告/法律文书等对准确性要求极高的场景 → BF16/FP16或AWQ INT4
 - 客服/摘要/信息抽取等一般场景 → GPTQ INT4
 - 边缘设备/离线部署 → GGUF Q4_K_M
- 量化选型的安全裕度：如果INT4精度不够用，不要硬撑，升级到INT8或换更大的卡。在政企项目中，模型回答错了比系统慢一点要严重得多。
- 售前必须做的验证：给客户做方案时，务必拿客户的真实数据(而不是通用基准)测试量化前后的效果。通用benchmark上的精度损失不代表你客户的业务场景也一样。

四、单卡并发测算方法

4.1 底层逻辑：显存是并发的天花板

很多人以为“算力越强并发越高”，这是一个常见误区。在推理场景下，并发数的天花板通常是显存，而不是算力。

为什么？因为每个同时在线的用户对话，都需要在显存里存一份自己的“记忆”——也就是KV Cache。你有100个用户同时聊天，显存里

就要存100份KV Cache。这些KV Cache是线性增长的——人越多，占的显存越多。

而算力呢？算力决定的是“生成速度”——每秒能生成多少token。算力不够，表现是回复变慢；而显存不够，表现是直接OOM(显存溢出)，服务崩了。

4.2 KV Cache精确计算公式

KV Cache存储的是每一层、每一个注意力头的Key和Value向量。精确公式如下：

单请求KV Cache(字节) = 2 × 层数 × KV头数 × 头维度 × 序列长度 × 精度字节数

- 其中：
- **2**：因为要同时存Key和Value两份
 - **层数**：Transformer的层数(如7B模型通常32层)
 - **KV头数**：GQA架构下KV头数远小于总头数(如总头数32，KV头数可能是4或8)
 - **头维度**：每个注意力头的维度，通常是128
 - **序列长度**：输入+输出的总token数
 - **精度字节数**：FP16为2，INT8为1

简化记忆版：对于常见的7B模型(FP16)，每个token的KV Cache大约是 **1 KB**。所以2000个token的上下文，一个请求大约占 **2 MB** 的KV Cache显存。

精确示例 (Qwen3-4B, FP16)：

- 层数L = 36
- KV头数N_kv = 8 (GQA架构)
- 头维度D_head = 128
- 精度 = 2字节

单token KV Cache = 2 × 36 × 8 × 128 × 2 = 147,456 字节 ≈ **0.144 MiB/token**

2000 token上下文 = 2000 × 0.144 = **288 MiB/请求**([CSDN · GPU服务器资源统计, 2026](#))

4.3 总显存与并发数计算

总显存 = 模型参数显存 + KV Cache总显存 + 系统开销

- 其中：
- **模型参数显存**：固定值，不随并发数变化
 - **KV Cache总显存** = 并发数 × 单请求KV Cache(与并发数成正比)
 - **系统开销**：CUDA上下文、运行时buffer等，通常1-3GB

反过来算最大并发数：

最大并发数 ≈ (可用显存 - 模型参数显存 - 系统开销) ÷ 单请求KV Cache

vLLM的实际算法：vLLM会在启动时先profile模型的静态显存占用，然后用以下公式计算KV Cache池大小：

KV Cache池大小 = 总GPU显存 × gpu_memory_utilization - 模型profile占用

然后再根据KV Cache池大小和单请求的KV Cache需求，计算最大并发数。默认 **gpu_memory_utilization = 0.9** (用90%显存，留10%给系统)。

举个完整的例子：

问题：A100 80GB显卡上跑Qwen3-7B INT4量化模型，上下文长度2048 tokens，最大并发多少？

计算：

- 模型参数显存(INT4)：7B × 0.5 = 3.5 GB ≈ 3.3 GiB
- 系统开销：约2 GiB
- 可用显存池：80 × 0.9 - 3.3 - 2 ≈ 66.7 GiB
- 单token KV Cache(FP16, Qwen3-7B: 28层 × 4 KV头 × 128维 × 2字节 × 2) ≈ 0.07 MiB
- 单请求(2048 token)：2048 × 0.07 ≈ 143 MiB
- 理论最大并发：66.7 × 1024 ÷ 143 ≈ **477 个请求**


但！ 这是纯理论值。实际并发还受限于计算能力——你不可能同时让400多个请求的token都在生成。vLLM通过continuous batching机制，让不同请求的生成token在时间上交错执行，所以实际“同时在线”的请求数可以很多，但每个请求的生成速度会变慢。

4.4 不同模型/不同GPU的并发参考

以下是生产环境中的经验值(基于FP16或INT4量化，seq_len=2048)：

模型	精度	GPU	理论最大并发	实际推荐并发	单用户吞吐
Qwen3-7B	INT4	RTX 4090 (24GB)	~100	30-50	~30-50 tok/s
Qwen3-7B	FP16	A100 80GB	~60	30-40	~50-70 tok/s
Qwen3-14B	INT4	RTX 4090 (24GB)	~40	15-25	~20-30 tok/s
Qwen3-14B	FP16	A100 80GB	~30	15-20	~40-60 tok/s
Llama-70B	INT4	2×A100 80GB	~20	8-12	~20-30 tok/s

重要提醒：并发数不是越高越好。并发太高，每个用户的等待时间会变长，P99延迟会恶化。合理的并发应该是：在满足延迟SLA(如首token < 1s, P99 < 3s)的前提下，尽可能提高并发数。企业级部署建议把理论并发打个5-7折作为安全值。



五、推理框架对比

5.1 从原生Transformers到专用推理引擎


原生Transformers 是最基础的推理方式——直接用HuggingFace的 `transformers` 库加载模型。它的优点是简单、兼容所有模型、灵活；缺点是性能差、显存利用率低。就像开一辆原厂素车，什么都能跑但跑得不快。

随着大模型推理成为独立的技术方向，出现了专门优化的推理引擎。它们主要从三个方面做优化：

- KV Cache管理**：用分页内存等技术减少显存浪费
- 批处理优化**：动态合并请求，提高GPU利用率
- 算子优化**：手写CUDA内核，减少计算开销

5.2 主流框架详细对比

框架	开发方	核心技术	吞吐量 (相对)	首token 延迟	显存效率	模型支持	硬件支持	学习曲线
原生Transformers	HuggingFace	基础实现	1x (基准)	基准	低	最广	CPU/NVIDIA/AMD	✧ 低
vLLM	UC Berkeley	PagedAttention	3-4x	快	极高	很广 (几乎所有HF模型)	NVIDIA/部分国产	✧✧ 中
TensorRT-LLM	NVIDIA	内核级优化+FP8	4-5x	最快	高	主流模型	仅NVIDIA	✧✧✧✧ 高
SGLang	LMSYS	RadixAttention	3-5x	快	极高	主流模型	NVIDIA	✧✧ 中
TGI	HuggingFace	FlashAttention + 动态批处理	1.5-2x	较稳定	中	HF生态	NVIDIA	✧ 低
LMDeploy	上海AI Lab	TurboMind推理引擎	2-4x	快	高	主流中文模型	NVIDIA/昇腾	✧✧ 中
Ollama/llama.cpp	社区	GGUF + CPU优化	0.5-1x	较慢	中 (CPU友好)	GGUF 格式模型	全平台	✧ 极低



数据来源：基于Llama-7B在A100单卡上的综合评测。具体性能因模型大小、batch size、序列长度而异。参考来源：(GitHub · Inference Engines Benchmark, 2025) (CSDN · AI Infra全解, 2026)

5.3 各框架核心特性详解

vLLM：目前最主流的生产级推理框架。核心创新是**PagedAttention**——受操作系统虚拟内存启发，把KV Cache分成固定大小的“页”，按需分配、用完即释放。这彻底解决了传统方式中KV Cache内存碎片化的问题，显存利用率从40-50%提升到90%以上。配合**连续批处理(Continuous Batching)**，吞吐量是原生Transformers的2-4倍(腾讯云 · vLLM与TGI对决, 2026)。

TensorRT-LLM：NVIDIA官方出品的“性能怪兽”。它的优势是**内核级优化**——FlashAttention、Fused MLP等手写CUDA内核，把GPU的算力榨到极限。在H100上，TensorRT-LLM的吞吐量比vLLM还高12-15%。但缺点是：首次编译时间长(70B模型可达28分钟)，模型更新需要重新编译，配置复杂，且只支持NVIDIA GPU(CSDN · 推理框架全景解析, 2025)。

SGLang：后起之秀，核心创新是**RadixAttention**——用Radix树(基数树)管理KV Cache，自动识别并复用请求之间共享的前缀。这在RAG和多轮对话场景下效果特别明显——100个用户问同一个文档里的问题，文档部分的KV Cache只需要计算一次，后续请求直接复用。实测在共享前缀场景下，SGLang比vLLM快20-29%(CSDN · AI Infra全解, 2026)。

LMDeploy：上海人工智能实验室开发的推理框架，是**国产算力生态的重要选择**。它的TurboMind推理引擎同时支持NVIDIA和昇腾等国产GPU，在国产卡上的适配度优于vLLM。对于需要做信创适配的政企项目，LMDeploy是更稳妥的选择。

5.4 政企场景选型建议

你的场景	首选框架	备选	理由
快速POC/原型验证	Ollama / LM Studio	vLLM	一行命令启动，零配置
通用生产部署	vLLM	SGLang	生态最成熟，模型支持最广，性能好
RAG知识库/多轮对话	SGLang	vLLM + Prefix Caching	RadixAttention对共享前缀场景加速显著
单一模型/极致吞吐	TensorRT-LLM	vLLM	吞吐量最高，但编译慢、灵活性差
国产算力/信创	LMDeploy	vLLM-Ascend分支	对国产GPU适配最好
边缘/无GPU	llama.cpp (GGUF)	Ollama	唯一选择，CPU也能跑
多模型混合部署	Ray Serve + vLLM	Triton	灵活的模型编排和调度

售前坑点：不要被“某某框架性能第一”的说法忽悠。性能只是选型的一个维度，**稳定性、生态、团队熟悉度、国产适配**往往更重要。对于政企客户，vLLM是最稳妥的默认选择——性能足够好，社区活跃，出了问题好查资料。只有在明确的性能瓶颈场景下，再考虑换TensorRT-LLM或SGLang。

六、多应用算力池化与复用


6.1 为什么需要算力池化

当客户有多个应用要上AI能力时(比如政务的公文助手、问答系统、代码助手、知识库检索等)，最常见的做法是“一个应用配一套GPU”。

这就导致了典型的“烟囱式”建设——每个应用的GPU利用率都很低(推理服务的GPU利用率通常只有20-40%)，加起来总投入很大但总体利用率很低。

算力池化的核心思路：把所有GPU放在一个共享资源池里，多个应用共享使用，按需分配、动态调度。就像从“每家一口井”变成“自来水厂统一供水”。

根据HeteroFlow项目的数据，传统调度下GPU平均利用率约为58%，通过智能调度可以提升到89%，提升幅度达71%(CSDN · HeteroFlow调度算法, 2026)。



6.2 池化技术路线对比

技术方案	原理	隔离性	利用率提升	性能损耗	适用场景
时间分片(MPS)	多进程共享GPU，时间片轮转	低(无硬件隔离)	高(可burst)	低	开发测试、非核心业务
MIG硬件分区	物理上把GPU切成多个实例	高(故障隔离)	中(固定分区)	几乎无	生产环境、多租户隔离
vGPU虚拟化	软件层模拟GPU，按显存切分	中	高	5-10%	云计算、虚拟桌面
GPU池化(OrionX等)	软件定义算力，远程调用GPU	高	极高(3-10x)	本地无损耗，远程取决于网络	数据中心级算力池
K8s调度 + 推理框架	容器级调度，动态扩缩容	中(容器隔离)	中高	低	微服务架构、云原生

NVIDIA MIG方案：在A100/H100等高端GPU上，可以通过MIG技术把一张卡物理上切成多个独立的GPU实例。比如一张A100 80GB可以切成7个MIG实例(每个约10GB显存)，每个实例有独立的计算核心、显存、缓存。优点是硬件级隔离，一个实例崩了不影响其他；缺点是分区大小固定，不能动态调整，分小了用不完浪费、分大了不够用(NVIDIA · MIG Guide, 2026)。

软件定义GPU池化：代表产品有趋动科技的OrionX(猎户座)。核心思路是在应用和物理GPU之间加一层软件抽象——应用调用逻辑vGPU，OrionX把vGPU需求匹配到具体的物理GPU。应用不用改代码(CUDA接口透明)，GPU可以跨服务器远程调用。官方宣称可将GPU综合利用率提升3-10倍(趋动科技 · OrionX白皮书, 2025)。

6.3 推理层的多应用复用策略

比“硬件级池化”更轻量也更实用的，是**推理层的多应用复用**——多个应用共享同一个模型推理服务。

实现方式：

- 共享推理API：**部署一个统一的大模型推理服务(如vLLM)，多个应用通过API调用同一个模型。这是最简单、成本最低的复用方式。
- 多模型服务化：**在同一个推理框架中部署多个模型(如vLLM支持多模型服务)，根据请求路由到不同模型。
- LoRA多租户：**同一个基座模型，加载不同的LoRA适配器来适配不同应用/不同行业。vLLM原生支持多LoRA serving，切换开销很小。

Hbox三池模型是一种更精细的资源划分思路：

- **独占资源池：**给核心业务/对延迟极度敏感的应用，资源独享、性能稳定
- **池化资源池：**给一般业务应用，共享使用、弹性调度
- **公共资源池：**给测试、开发、离线任务，用闲置资源跑，可被抢占

这种分层方案既能保障核心业务的稳定性，又能提高整体资源利用率(CSDN · Hbox算力调度, 2026)。

6.4 政企最佳实践

对于政企客户，推荐采用“分层池化”策略：

- 1. **第一层(应用层)**：同一类应用共享同一个推理服务实例。比如所有的RAG知识库应用共享一个Qwen3-14B推理服务。
- 2. **第二层(框架层)**：用vLLM/K8s做推理服务的动态扩缩容，流量高峰时自动加实例。
- 3. **第三层(硬件层)**：对于GPU数量较多(>10张)的场景，引入GPU池化方案(如OrionX或昇腾的Atlas算力池)，实现跨服务器的算力共享。
- 4. **第四层(调度层)**：建立算力配额和调度机制，不同部门/应用按优先级分配算力资源。


售前建议：不要一上来就给客户推全套算力池化方案。第一期先把推理服务做好(第一层+第二层)，让客户看到效果。等应用多了、GPU数量上来了，再考虑硬件层的池化。算力池化本身有成本和复杂度，不要为了“池化”而池化。

七、算力选型：英伟达 vs 国产路线

7.1 主流AI芯片参数对比

芯片	厂商	FP16算力	显存/带宽	功耗	参考价格	相对H100性能	软件生态
H100 80GB SXM	NVIDIA	989 TFLOPS	80GB HBM3 / 3.35TB/s	700W	~25万	100% (基准)	CUDA生态最完善
A100 80GB	NVIDIA	312 TFLOPS	80GB HBM2e / 2.0TB/s	400W	~8万 (二手)	~40%	CUDA生态成熟
RTX 4090	NVIDIA	330 TFLOPS	24GB GDDR6X / 1TB/s	450W	~1.5万	~25%(推理)	消费级驱动，限制较多
昇腾910C	华为	640-800 TFLOPS	128GB HBM2e / 3.2TB/s	~500W	~18-22万	~60-80%	CANN/MindSpore，迁移成本高
昇腾910B	华为	320 TFLOPS	64GB HBM2e / 1.6TB/s	310W	~12万	~30-40%	CANN生态，持续完善
寒武纪思元590	寒武纪	256 TFLOPS	96GB HBM2e / 1.2TB/s	~300W	~6-7万	~25-30%	MLUarch，生态较弱
海光深算二号	海光信息	256 TFLOPS	64GB / ~800GB/s	~300W	~8-10万	~25-30%	ROCm兼容，迁移成本较低
摩尔线程MTT S5000	摩尔线程	~200 TFLOPS	64GB	—	—	~20%	CUDA兼容层，生态建设中

数据来源：综合公开资料整理，具体性能因测试场景而异。参考来源：(CSDN · GPU选型指南, 2026) (36氪 · 国产GPU, 2025) (腾讯云 · 国产AI芯片, 2026)



7.2 多维对比分析

对比维度	英伟达路线	国产路线(昇腾为代表)	对政企的影响
绝对性能	最强, H100/H200是行业标杆	约为同级别英伟达的60-80%	同等模型规模, 国产卡需要更多数量
软件生态	CUDA生态垄断, 所有框架/模型原生支持	CANN/ROCm兼容层, 主流模型已适配但需移植	国产卡部署周期长1-3个月, 需预留适配时间
供货稳定性	受出口管制影响, H100/H800供货紧张	国内生产, 供货有保障	信创项目必须选国产, 非信创可考虑混合方案
采购成本	H100约25万/张, 且需溢价	910C约18万/张, 性价比更高	国产卡单卡便宜30-50%, 但总拥有成本需考虑工程投入
信创适配	不属于信创目录	符合信创要求, 央国企采购加分	政务/国企项目通常有信创要求
技术支持	社区资源丰富, 问题容易搜到	厂商支持为主, 社区资源较少	出问题, 国产卡更依赖厂商响应速度
长期风险	出口管制升级风险	技术追赶风险, 可能代差持续	战略安全角度, 国产路线是必选项

7.3 政企选型建议

决策树:

客户有没有信创要求？

有 (政务/国企/涉密) → 选国产路线

- 预算充足 + 大模型 → 昇腾910C / 910B集群
- 预算有限 + 中小模型 → 海光DCU / 寒武纪思元
- 推理框架 → LMDeploy (国产适配最好)

没有信创硬性要求

- 追求极致性能 + 预算充足 → H100 / H800
- 性价比优先 → A100 80GB (二手/翻新)
- 轻量级推理 + 成本敏感 → RTX 4090 (注意驱动限制)
- 推理框架 → vLLM (通用首选) / TensorRT-LLM (极致吞吐)

关键提醒:

- 不要按1:1比例换算:** 很多售前会简单地讲“昇腾910B约等于A100”, 这是不负责任的。实际性能取决于具体模型、框架、优化程度, 建议一定要做**POC实测**。
- 考虑全生命周期成本:** 国产卡虽然单卡便宜, 但需要额外的适配工程成本(1-3个月人力)、持续的调优成本, 以及可能的性能损耗带来的额外卡数需求。总拥有成本(TCO)不一定更低。
- 留出迁移窗口:** 如果客户未来可能要做信创替代, 现在选英伟达路线时就要考虑可迁移性——尽量用PyTorch原生、避免深度绑定CUDA的算子。

八、完整的算力评估方法论

8.1 六步评估流程

针对政企客户多个应用升级AI的场景，建议按以下流程开展算力评估：

第一步：业务调研摸底

核心目标：搞清楚客户到底有多少个应用要上AI，每个应用的使用场景和并发量。

需要向客户调研的关键问题清单：

调研项	具体问题	为什么要问
应用清单	有多少个应用计划接入大模型？分别是什么？	确定需要几套模型、是否可复用
使用场景	每个应用是做什么的？(问答/摘要/生成/代码/多模态)	决定模型选型(7B/14B/MoE)
并发用户数	峰值同时在线多少人？平均多少？	直接决定算力需求
对话特征	平均对话多长？输入输出各多少token？	决定KV Cache显存占用
响应要求	能接受的等待时间是多少？(首token/总时间)	决定推理框架和算力规模
数据敏感性	数据是否涉密？是否有等保要求？	决定是否必须私有化、是否需要信创
现有硬件	目前有什么GPU服务器？数量多少？	判断能否利旧，减少新增投入
未来规划	未来1-2年还会增加什么应用？	预留扩容空间，避免重复建设

售前技巧：客户通常自己也不说不清具体并发数。可以用"高峰时段多少人同时用"、"每天大概多少次对话"来间接推算。例如，每天1000次对话，每次对话平均3分钟，高峰集中在2小时内，那么峰值并发大约是 $1000 \times 3 / 120 \approx 25$ 。

第二步：厂商调研与模型选型

针对每个应用场景，选择合适的模型：

场景类型	推荐模型	推荐精度	显卡建议
简单问答/客服	Qwen3-7B / DeepSeek-7B	INT4 (AWQ/GPTQ)	RTX 4090 (24GB)
文档摘要/信息抽取	Qwen3-14B	INT4 / INT8	RTX 4090 / A10 24GB
知识库RAG(深度)	Qwen3-14B~32B	INT8 / FP16	A100 40GB+
代码生成/分析	DeepSeek-Coder-V2 / CodeLlama	INT4	RTX 4090 / A100
复杂推理/政务公文	Qwen3-32B / GLM-4-9B	FP16	A100 80GB
多模态(图文)	Qwen2.5-VL / 智谱GLM-4V	INT4 / FP16	需多模态模型，显存更大

选型原则：**够用就好，按需升级**。先用小模型做POC，验证业务价值后再根据实际效果决定是否升级更大的模型。

第三步：算力估算

使用以下公式进行容量规划：

(1) 模型数量与规格

总模型数 = 不同应用所需的不同模型数量
(注：同类型的应用可以共享同一个模型)

(2) 单模型显存需求

单模型显存 = 模型参数显存 + KV Cache预留 + 系统开销
模型参数显存 = 参数量(GB) × 精度系数 (FP16=2, INT8=1, INT4=0.5)
KV Cache预留 = 峰值并发数 × 平均上下文长度 × 单token KV大小
系统开销 = 2-4GB (CUDA上下文、运行时buffer)

(3) 总GPU显存需求

总显存需求 = Σ(每个模型的显存需求 × 副本数)
(副本数 = 高可用冗余 + 负载均衡所需)

(4) 算力验证

总算力需求(TOPS) = 总并发生成token数/s × 每token计算量 × 冗余系数
冗余系数建议：1.5-2.0 (考虑波峰、扩容、突发流量)

实操示例：

场景：某政务单位，3个应用(公文助手、政策问答、代码辅助)，峰值并发共50人，数据涉密需信创。

选型：

- 公文助手: Qwen3-14B INT8, 20并发, 2048上下文 → 显存~18GB
- 政策问答: Qwen3-14B INT8, 20并发, 2048上下文 → 显存~18GB (可与公文助手共享模型)
- 代码辅助: DeepSeek-Coder-7B INT4, 10并发 → 显存~6GB

计算：

- 模型1(14B INT8): 14GB参数 + 20×0.2GB KV + 2GB开销 ≈ 20GB
- 模型2(7B INT4): 3.5GB参数 + 10×0.1GB KV + 2GB开销 ≈ 6.5GB

- 合计(1张卡跑两个模型): ~26.5GB → 需要至少32GB显存的GPU
 - 考虑国产信创: 昇腾910B (64GB) 可以放下两个模型 + 冗余空间
 - 高可用: 至少2张卡(主备), 推荐4张卡(2+2负载均衡)

结论: 4张昇腾910B, 推荐使用LMDeploy推理框架, 做模型服务共享。

第四步：硬件选型与配置

根据第三步的计算结果，选择具体的硬件方案：

方案等级	GPU配置	支持模型规模	并发能力	适用客户
入门级	2×RTX 4090 (24GB)	7B-14B INT4	50-100	科室级、小范围试点
标准级	2×A100 80GB / 4×昇腾910B	14B-32B	100-200	部门级、生产环境
企业级	8×A100 / 8×昇腾910C	32B-70B MoE	200-500	企业级、多应用共享
集群级	32+卡集群	70B+ / MoE大模型	500+	集团级、智算中心

服务器配置建议：

- CPU：每卡配8-16核CPU(用于数据预处理和调度)
- 内存：至少2倍GPU显存(用于CPU卸载和模型权重缓存)
- 存储：NVMe SSD，预留200GB以上(模型文件+缓存)
- 网络：多卡服务器建议InfiniBand或RoCE(张量并行需要)

第五步：池化与调度规划

根据应用数量和GPU规模，规划池化架构：

- **2-4卡**：不需要复杂池化，直接按应用分配
- **5-10卡**：用K8s + vLLM/LMDeploy做推理服务调度
- **10卡以上**：考虑引入GPU池化方案(如OrionX/昇腾算力池)
- **50卡以上**：建设智算中心级算力平台，统一调度

第六步：一期落地与验证

建议采用"小步快跑、快速迭代"的策略：

- POC阶段(1-2个月)**：选1-2个最痛的应用，用最小配置(单卡或双卡)跑通，验证效果
- 一期建设(3-6个月)**：上线3-5个核心应用，建设基础算力平台(4-8卡)，跑通运维流程
- 二期扩展(6-12个月)**：全面推广应用，扩展算力规模，引入池化和调度优化
- 持续运营**：建立监控体系，持续优化资源利用率

8.2 售前关键风险点

- 并发估算不足**：客户往往低估峰值并发。建议按客户估的数翻倍再算，宁多勿少。
- 模型选型偏大**：客户一上来就要“最大的模型”。要引导客户从7B开始试，够用就好。
- 忽略运维成本**：很多方案只算硬件成本，不算运维人力。大模型部署不是“装完就完事”，需要持续调优、监控、升级。
- 国产化适配风险**：承诺国产卡“即插即用”是危险的。一定要留足适配时间，并明确告知客户可能的性能差异。
- 精度损失争议**：量化后的模型效果要和客户一起验收，不要自己觉得“差不多”。对政企客户，准确性比速度重要。

九、政企行业最佳实践与案例

9.1 煤炭行业案例

案例1：彬长矿业孟村矿 — 灾害治理知识库

- 方案：基于RAGflow平台二次开发，采用“本地大模型+RAG增强检索+可视化交互”架构
- 模型：本地化部署高性能大模型(推测为Qwen或同级别7-14B模型)
- 效果：推理速度20-30 token/s，满足日常查询与应急决策的实时性需求
- 价值：打通资料壁垒，技术资料检索速度与准确性显著提升，为安全预案制定和应急决策提供数据支撑
- 启示：煤矿场景对数据安全要求高(数据不出矿)，本地化部署是刚需；知识库RAG是最容易落地的场景(中国网·彬长矿区, 2025)

案例2：鄂尔多斯煤矿 — 矿洞视界云盒

- 方案：盘古大模型推理能力下沉到井下边缘设备，结合矿下摄像机和视频流
- 效果：传统地上集中AI的3-5秒识别延迟缩短到500毫秒内，就地联动作业设备处理
- 特点：井下AI分析设备自成系统，不依赖工业环网，停电断网可正常工作
- 启示：边缘推理在煤矿井下场景有特殊价值——低延迟、高可靠、网络独立(鄂尔多斯市政府·2026)

9.2 政务行业案例

案例：鄂尔多斯市 — 政务大模型与根数据库

- 方案：政务外网侧部署DeepSeek-R1大模型，与“根数据库”应用平台互联互通
- 效果：赋能基层工作人员快速获取信息，提升治理效率和科学化水平
- 技术底座：华为云平台+一体化算力体系，覆盖全市的数据治理体系(政务数据超10亿条)
- 启示：政务场景的核心需求是数据安全(不出政务网)和信息检索效率；大模型与政务数据平台的打通是关键(鄂尔多斯应用技术学院·智慧城市研究, 2026)

9.3 行业落地的共性经验

- 从知识库切入，从点到面**：几乎所有成功案例都是先从“知识库+RAG”场景起步(门槛最低、见效最快)，再逐步扩展到更多场景。不要一上来就做“通用AI平台”。
- 数据是核心资产**：大模型只是大脑，企业自己的数据才是知识。RAG架构的效果，70%取决于数据质量(文档是否完整、结构化程度如何)，30%取决于模型。
- 先小后大，验证价值再扩容**：用7B模型+单卡做POC，花几万块钱验证业务价值，确认有用了再投几百万建集群。上来就买一柜子GPU的，最后大概率闲置。

4. **算力要留余量，但不要过度冗余**：建议预留30-50%的扩容空间(应对应用增加和并发增长)，但不要按“未来5年最大需求”一次性买满。算力硬件更新很快，3年前的卡在现在可能只有新卡1/3的性能。
5. **重视运维能力建设**：大模型服务不是部署完就完事了。需要监控显存、监控延迟、监控错误率，还需要定期更新模型、优化prompt、扩充知识库。客户没有运维团队的话，要把运维服务一起打包。

十、总结与行动建议

10.1 核心结论

- 模型选型**：政企本地化部署的最优路径是“从开源入手，按需升级”。Qwen3系列(Apache 2.0协议+中文优化+生态完善)是最稳妥的起点，7B模型单卡即可运行，14B模型适合生产环境，30B MoE用于高要求场景。
- 量化是必选项**：INT4量化(AWQ或GPTQ)可以在精度损失可接受(3-5%)的前提下，将显存需求降低75%，是性价比最高的优化手段。政企核心业务建议AWQ INT4(精度更好)，一般场景用GPTQ(速度更快)。
- 并发瓶颈在显存**：并发数主要受限于KV Cache的显存占用，而非GPU算力。计算并发的核心公式：最大并发 $\approx$ (可用显存 - 模型参数显存) $\div$ 单请求KV Cache。实际部署建议打5-7折作为安全值。
- 推理框架选vLLM**：除非有极致性能需求(TensorRT-LLM)或RAG专属场景(SGLang)，否则vLLM是生产部署的最佳选择——性能好、生态成熟、社区活跃、上手容易。
- 国产路线可落地但需谨慎**：昇腾910C在推理场景已达到H100的60-80%性能，且供货有保障、符合信创要求。但要预留1-3个月的适配周期，不要按1:1替换的预期立项。
- 算力池化是中期方向**：应用数量少于5个、GPU少于5张时，不用搞复杂的池化。当应用和GPU数量上来后，先做推理层的服务共享，再考虑硬件层的GPU池化。

10.2 给售前工程师的行动清单

- ☐ **摸底客户现状**：用本章第八节的调研清单，把客户的应用数量、并发、数据敏感性、现有硬件摸清楚
- ☐ **选型匹配**：根据场景选模型(7B起步)、根据并发算显存、根据信创要求选GPU路线
- ☐ **做POC验证**：选最痛的1-2个场景，用最小配置(2卡)跑通，给客户看真实效果
- ☐ **量化效果对比**：拿客户的真实数据，测FP16 vs INT8 vs INT4的效果差异，让客户自己选
- ☐ **压力测试**：用locust等工具测真实并发能力和延迟，用数据说话
- ☐ **规划演进路线**：给客户画一张从POC→一期→二期的路线图，让客户知道每一步花多少钱、得到什么
- ☐ **讲清楚风险**：国产化适配的风险、量化精度的风险、运维成本的风险——提前说清楚比事后扯皮强

最后一句话：算力评估不是“算出来”的，而是“测出来”的。公式和经验值只能给你一个大范围，真正准确的数字一定要在客户的真实环境、真实数据、真实负载下实测得到。好的售前方案，不是把参数列得最全的，而是最贴近客户实际需求、并且有验证数据支撑的。

数据来源说明

本报研的核心数据与技术参数均来自公开可验证的来源，主要包括：

数据类型	主要来源	说明
模型参数与硬件要求	各模型官方文档、CSDN技术博客、掘金社区	交叉验证后采用中位数
量化技术对比	CSDN技术博客、HuggingFace文档、技术问答	基准测试数据来自MMLU
推理框架性能	GitHub基准测试项目、技术博客、评测文章	基于Llama-7B/A100基准环境
GPU参数与性能	厂商官网、IDC市场报告、36氪、技术分析文章	价格为2026年市场参考价
国产芯片对比	华为开发者联盟、腾讯云开发者社区、36氪报道	性能为多源综合估算
行业案例	政府官网、中国网、学术期刊、企业公开报道	均为已公开的落地案例
算力池化数据	趋势科技白皮书、NVIDIA技术博客、开源项目文档	利用率数据为厂商/项目宣称

注意：本报研中的性能数据、价格数据等均来自公开资料整理，具体数值可能因测试环境、硬件配置、软件版本等因素而有所差异。实际项目中应以POC实测数据为准。